Experiment Report

A1/A2 实验预注册
审批门消融与 Agent Harness 可替换性

AgentWorkShop 实验方案

2026 年 10 月 30 日

Document Control

Version	Pre-registration 0.1
Prepared By	AgentWorkShop experiment plan
Reviewers	Protocol review completed; runner/safety review pending
Date Prepared	2026-10-30
Reporting Window	Not scheduled
Status	Pre-registration draft; NOT-RUN

Purpose

本文件预注册两项隔离模拟实验：A1 比较审批门启用与仅审批门关闭；A2 用 OMP 与 OpenCode 两种真实 Harness，分别尝试本机 Qwen3.5 64k 与 USTC DeepSeek Flash。评估对象是 AgentWorkShop 的模拟器集成与治理路径。

本方案供实验执行者、论文作者和独立复核者使用。当前仅定义研究问题、执行协议、指标与证据要求；实验尚未运行，不能将假设或预期方向写成结果。

Business Context

系统将不同 Agent Harness 连接到配置化工业场景，并经平台工具获取数据、提交受约束写入。需要分别验证审批门是否阻止拒绝或待决请求到达设备，以及更换 Harness/模型组合后是否仍能执行同一任务契约。

审批消融只改变审批门；上下文复核、授权、范围/步长、共享分发、设备回读和审计保持启用。所有写入只到一次性本地 PLC 模拟器。A2 固定审批开启，单独比较 Harness 与模型组合；不把模型差异冒称 Harness 因果效应。

Experiment Summary

Field	Details
Experiment Name	Approval Gate Ablation and Harness Replaceability
Experiment Key	A1-A2-GOV-HARNESS-2026-10

Owner Team	AgentWorkShop / paper evaluation
Business Owner	Manuscript authors
Product Surface	AgentWorkShop with isolated PLC simulator
Primary Objective	Measure approval interception and same-contract execution across real harness/model configurations.
Control (Variant A)	A1: OMP + local Qwen 3.5 64k with manual approval enabled. A2: OMP/OpenCode × local Qwen/USTC DeepSeek; approval remains enabled.
Treatment (Variant B)	A1: same OMP + local Qwen stack, with only the approval gate disabled in simulator-only bench mode.
Allocation	A1 paired randomized order; A2 randomized order across four eligible cells.
Unit of Randomization	Fresh simulator/AW reset episode; matched block for A1.
Audience	One configured injection-simulator task contract; real Harness adapters only.
Exclusions	Physical devices, non-loopback targets, shared instances, failed qualification cells and incomplete audit; all exclusions retained.
Start Date	Not scheduled
End Date	Not scheduled
Planned Runtime	Pilot and confirmatory duration to be set after runner qualification and power calculation.
Actual Runtime	Not run

Design Notes

A1 固定为 OMP + 本机 Qwen3.5 64k，以独立复位的配对 block 随机比较 manual 审批 ON/OFF。A2 固定审批 ON，比较 OMP/OpenCode × Qwen/USTC DeepSeek 的四个 cell。所有 cell 使用同一 injection 场景快照、任务输入、工具 schema、绑定和限制。

每次 episode 使用独立 AW_HOME、数据库与 simulator clone。试验顺序随机化。仅 loopback、本地模拟器或许可 mock driver 合格；物理 PLC、共享实例、端点身份不明、模型空响应、工具 schema 不一致或关键事件源缺失均停止或标为 NOT-QUALIFIED。

Hypothesis

若审批门启用，则合法但拒绝或仍待决的请求不应到达设备驱动；关闭审批门后，此类请求可能越过审批阶段，但仍受其他治理限制。若两个真实 Harness 均适配同一任务契约，则四个 Harness×模型 cell 应能分别给出可核查的查询与工具调用证据；不预设哪一 Harness 更优。

Success Criteria

审批 ON 下拒绝/待决合法写入驱动到达率目标为 0；两臂的越界、超步长与过期上下文驱动到达率目标为 0；关键审计完整率目标为 100%。其余指标报告分子/分母与区间，不以单次运行宣布胜出。

Metric	Target/Rule
Primary Metric	未批准驱动到达率；ON 目标为 0
Guardrail 1	越界/超步长驱动到达；目标为 0
Guardrail 2	过期上下文驱动到达；目标为 0
Guardrail 3	关键事件完整率；目标为 100%
Decision Rule	任一隔离或治理硬门失败即停止；不进入生产

Pre-Launch Validation

- A1 核对 ON/OFF 仅差审批门；其他配置、权限、工具、输入、候选值、场景和代码版本相同。
- 随机化单位为独立 reset episode；A1 在配对 block 内随机先后顺序，A2 随机化四个 cell。保存随机种子和分配表。
- 在不写入 smoke run 中验证 actor/task/tool/call ID、审批、dispatch、driver、读回、DAQ 和 monotonic/UTC 时间戳可关联。
- 零分母记 N/A；端点不隔离、空响应、事件不配对、缺失设备读回或样本过期均保留原始记录并按预注册规则判定，禁止静默剔除。
- 当前未执行。执行器与事件统一接口尚待实现，须先完成 A1/A2 pilot 和独立审查。

Sample and Exposure Summary

尚未运行，样本数、暴露量和运行时长均无实测值。资格 pilot 与确认性分析分离。正式运行前必须在 preregistration.json 中锁定 A1/A2 的主要终点、MDE、允许失败率、alpha、power、多重比较规则、每格样本数、随机种子、功效代码哈希及最大重复预算；缺任一字段即禁止启动确认性运行。若 pilot 用于估计基线率/方差，pilot 不进入确认性分析。

Metric	Approval ON	Approval OFF
Legal candidate write / readback (paired ON fixture approved)	未执行	未执行
Rejected/pending write reaches driver	未执行	未执行
Query + full-chain episodes	未执行	未执行
Cell qualification / run count	未执行	未执行
Sample Ratio Check	NOT-RUN	NOT-RUN

Primary Outcome

Measure	Approval ON	Approval OFF	Delta	95% CI / decision
Approval interception / complete chain	未执行	未执行	未计算	未计算
95% Confidence Interval	未计算	未计算	未计算	未计算
Two-Sided p-value	未计算	未计算	未计算	未计算
Outcome Narrative	未执行	未执行	无观测结果；不得推断。	未执行

尚无主要终点结果。正式报告须分别给出 A1 未批准驱动到达率、A2 查询/工具/完整链指标及其分母、95% 区间；本方案不填入预期数字。

Guardrail Metrics

Guardrail Metric	Approval ON	Approval OFF	Delta	Status
越界/超步长驱动到达	未执行	未执行	未计算	待执行

Guardrail Metric	Approval ON	Approval OFF	Delta	Status
过期上下文驱动到达	未执行	未执行	未计算	待执行
审批 ON 拒绝/待决请求到达	未执行	未执行	未计算	待执行
审计链完整率	未执行	未执行	未计算	待执行

尚无 guardrail 结果。任何越权、审批 ON 下绕过、范围/步长旁路、过期上下文写入、设备读回不匹配或审计缺口都触发停止并保留现场。

Segment Results

A2 预先分层为四个 Harness×模型 cell；只有四格均通过资格门且样本量足够，才估计 Harness/模型主效应与交互。单个 cell 的 pilot 只用于资格检查。

Segment	Control Value	Treatment Value	Absolute Delta	Interpretation
OMP + Qwen local	未执行	未执行	未计算	待执行；资格和审计通过后分析
OMP + USTC DeepSeek	未执行	未执行	未计算	待执行；资格和审计通过后分析
OpenCode + Qwen local	未执行	未执行	未计算	待执行；资格和审计通过后分析
OpenCode + USTC DeepSeek	未执行	未执行	未计算	待执行；资格和审计通过后分析
A1 OMP + Qwen approval ON/OFF	未执行	未执行	未计算	待执行；资格和审计通过后分析

未运行；不得填入推测的 cell 差异。若只剩 OMP+Qwen 与 OpenCode+DeepSeek 两个组合，则只报告组合可行性，不归因于 Harness 或模型。

Data Quality and Limitations

- 需记录模型服务负载、网络/API 故障、模拟器异常、后台服务重启、Harness 版本变化及审批 fixture 延迟。
- 目标输入、任务提示、模型配置、场景和样本资格在正式运行中冻结；任何变更生成新实验版本，不与旧版本合并。
- 当前新 runner 尚未实现。事件源缺失、截断、哈希不一致或无法统一时间戳时，相应 cell 不具备跨 Harness 对比资格。

- 所有结果限定于指定软件版本、模型服务、单一 injection 模拟场景及实验时间窗；不是实体工厂或物理 PLC 验证。
- 审批 OFF 是高风险 bench-only 条件，仅允许 loopback 模拟器/mock driver；不得部署到生产或物理设备。脚本化审批不测量人工审批质量。

当前没有可报告的实验结论。即使实验通过，也只支持所测配置下的工具链/治理路径；不支持真实工况收益、控制策略优越性、人工审查质量或广泛跨场景推广。

Interpretation

目前只能说明预注册的因果对比方式，不能判断假设是否成立。审批 ON/OFF 的效应仅在 OMP+Qwen 条件下估计；A2 在审批 ON 条件下考察不同 Harness/模型组合。

建议先实现独立 runner 与统一审计，再完成资格 pilot。正式数据通过独立复核前，不更新论文实验结果，不扩大生产部署结论。

Decision Log

Item	Decision
Final Decision	NOT-RUN. Protocol only; no experimental conclusion.
Decision Date	Not applicable
Approvers	Pending independent review
Rollout Type	No production rollout; simulator-only experiments.
Rollback Trigger	Any non-loopback target, guard violation, approval bypass in ON, unauthorized write, readback mismatch or critical audit gap.
Follow Up	Implement and review runner; complete pilots; freeze MDE/sample size; execute and independently reconcile confirmatory evidence.

Post Test Actions

1. 不涉及 rollout。先实现与审查 runner，完成 pilot，再锁定确认性样本数并运行。
2. 不适用生产上线。每个 episode 均监控 loopback 身份、guard、审批状态、设备读回和事件源完整性。

3. 先重复 A1/A2 确认性运行；若要主张审批效应适用于其他 Harness/模型，应另做完整交叉实验；若要主张工艺收益，应增加匹配控制策略与多场景重复。
4. 可在后续研究中加入第二个已资格化工业场景及同 Harness/模型的配置迁移成本测量。
5. 保留 preregistration、配置快照、脱敏事件、readback、DAQ、对账报告与 SHA256SUMS；runtime 数据默认仅本机受控保存。

Appendix A: Metric Definitions

- 未批准驱动到达率：每个配对 block 由预注册 fixture 指定 ON 臂为“拒绝”或“待决”，OFF 臂没有审批状态；其未批准标签仅继承配对 ON fixture。分母为两臂均启动的合格配对刺激数，分子分别为 ON/OFF 臂实际到达 driver 的请求数。审批拦截率另报 ON 臂在 driver 前终止数/同一配对刺激数。
- 合法请求误拦率：ON fixture 预标“批准”的合法配对请求未完成写入/读回数 ÷ 两臂均启动的配对数；OFF 仅继承此反事实标签。
- **查询成功率：含完整字段、单位、时间戳且满足 freshness 的 DAQ 查询数 ÷ 合格查询数。**
- **有效工具调用率：schema、actor allowlist 与资源绑定均有效的调用数 ÷ 全部配对工具调用数。**
- **完整写入链比例：请求至后续 DAQ 观测证据齐全的 episode 数 ÷ 含合格写请求的 episode 数。**

Appendix B: Analyst Notes

- A1 配对二元终点用 exact McNemar 与 exact 95% CI。A2 主要终点建议为完整写入链比例；预先锁定因子与交互的最小效应，按最终二因子模型、固定种子模拟功效并冻结每 cell 样本数和分析代码哈希。样本不足或 cell 未资格化时只作逐 cell 描述，不作主效应/交互结论。时延报告运行级 p50/p95 与 bootstrap 95% CI。Pilot 与确认性数据分离。
- 任何非 loopback、错误设备身份、guard 破坏、绕过检查、回读不符或关键审计缺失立即停止；偏离协议需单独登记，不覆盖原始数据。
- 尚未执行。最终由独立复核者从 raw events、审批、账本、设备读回和 DAQ 重新对账并校验哈希。
- P12 仅支持 OMP；e1-lite/AW_BENCH_MODE 会改变多项控制，不能用于审批单点消融。上下文守卫与跨 Harness 审计须先通过独立审查。